

Programación para la Ciencia de Datos

Entrega 2

Nombres integrantes: Gino Andrades Medina, Yaii Selti Ramos, Miguel Villarroel Vergara

Asignatura: programación para la ciencia de datos

Docente: Jazna Patricia Meza Hidalgo

Índice

1. Resumen ejecutivo

1.1 Propósito

- El objetivo fundamental de este sistema analítico es predecir de forma temprana el comportamiento de abandono voluntario de servicios (Churn) en una base de datos compuesta originalmente por 20.400 clientes bancarios. En la gestión moderna de instituciones financieras, la retención activa de usuarios representa una de las estrategias con mayor retorno de inversión, dado que el costo de adquisición de nuevas cuentas supera exponencialmente los recursos necesarios para fidelizar a los clientes existentes. Para cumplir con este propósito, la solución se estructuró bajo estándares rigurosos de ingeniería de software, aislando la lógica productiva en scripts modulares y automatizando los flujos a través de pipelines reproducibles de Scikit-Learn.

1.2 Resultados claves

Durante este ciclo de desarrollo, enfocado en la manipulación de datos y establecimiento de modelos de referencia, se lograron consolidar los siguientes hitos técnicos:

- **Saneamiento Automatizado:** Se eliminaron 400 registros duplicados puros, se corrigieron montos bajo cero en las variables de deudas e ingresos transformándolos a valor absoluto, y se gestionaron vacíos de información en campos financieros críticos (ingreso mensual, gasto y score crediticio) mediante imputación iterativa condicionada por el tipo de plan.
- **Ingeniería de Variables:** Se inyectaron exitosamente ratios de apalancamiento financiero e indicadores temporales de inactividad que incrementaron de forma sustancial la capacidad discriminante del sistema.
- **Diagnóstico de Líneas Base:** Se auditaron tres algoritmos clasificadores bajo sus parámetros por defecto, identificando un sesgo estructural crítico provocado por el desbalance de clases que hacía inviable el uso del umbral estándar.
- **Calibración Operativa:** Mediante un análisis avanzado de optimización de umbrales (Threshold Shifting), se determinó que desplazar la barrera decisional al rango 0.25 - 0.35 permite capturar preventivamente el 80% de las fugas de capital.

2. Metodología de Saneamiento e Ingeniería de Características Modular

2.1. Saneamiento Defensivo de Datos Crudos

La lógica de procesamiento inicial fue desarrollada dentro del script productivo `src/data_preprocessing.py`. El flujo defensivo limpia el conjunto de datos de manera uniforme para evitar el riesgo de sobreajuste por repetición de registros (overfitting) o distorsiones estadísticas provocadas por valores atípicos extremados. Los pasos ejecutados corresponden a:

- **Tratamiento de Duplicados e Inconsistencias:** Remoción estricta de filas idénticas y normalización de signos negativos en variables de monto absoluto mediante la aplicación de funciones vectoriales de valor absoluto.
- **Tratamiento de Outliers (Clase Winsorizer):** Implementación de una transformación personalizada que trunca simétricamente los percentiles extremos (1% inferior y superior), acotando la dispersión de variables altamente inestables sin eliminar filas del dataset.
- **Filtrado de Multicolinealidad:** Exclusión dinámica de variables redundantes que presenten un índice de correlación lineal superior a 0.90, resguardando la estabilidad de los coeficientes en modelos lineales.

2.2. Construcción de Ratios Financieros y de Comportamiento

- Se diseñó una función modular de ingeniería de características para inyectar variables sintéticas capaces de describir de mejor forma el perfil de riesgo y la fidelidad de los usuarios del banco:

Variable Sintética	Fórmula / Lógica	Impacto e Interpretación en el Negocio
ratio_deuda	$\text{deuda_total} / \text{ingreso_mensual}$	Determina el grado de apalancamiento del cliente. Valores elevados exponen vulnerabilidad financiera y propensión al abandono de productos.
ratio_gasto	$\text{gasto_mensual} / \text{ingreso_mensual}$	Mide la capacidad de consumo y

Variable Sintética	Fórmula / Lógica	Impacto e Interpretación en el Negocio
		nivel de liquidez. Identifica perfiles con nulo margen de ahorro dentro de la institución.
indice_lealtad	antigüedad_meses / frecuencia_compra	Establece la relación de permanencia frente al uso activo del servicio, aislando cuentas antiguas inactivas de usuarios fidelizados.
riesgo_por_inactividad	ultima_compra_dias / antigüedad_meses	Monitorea de forma proporcional el enfriamiento transaccional. Es un indicador directo y preventivo de desvinculación comercial.
region_uso_app	region + "_" + uso_app	Interacción categórica que segmenta geográficamente la adopción digital del banco, permitiendo aislar patrones territoriales de Churn.

3. Modelamiento supervisado y la evaluación de líneas base

3.1. Diseño de Canalizaciones y Partición Estratificada

El modelamiento supervisado se estructuró dividiendo el conjunto de datos de forma estrictamente estratificada (80% entrenamiento y 20% prueba) con una semilla fija (random_state=42) para mitigar el sesgo derivado del desbalance natural de la variable de abandono. Se acopló un ColumnTransformer para escalar numéricamente los montos e indicadores y codificar binariamente las categorías. Variables identificadoras sin valor explicativo directo (como id_cliente y codigo_postal) fueron excluidas de manera automática mediante el parámetro remainder='drop'.

3.2. Matriz de Desempeño Empírico de Modelos Base

- Se entrenaron tres algoritmos en su estado inicial (Línea Base) para evaluar de manera cruzada su capacidad de clasificación utilizando las funciones del script `src/model_evaluation.py`. Las métricas obtenidas en el conjunto de testeo corresponden a los siguientes valores reales de ejecución:

Modelo Línea Base (Umbral 0.50)	Accuracy General	Precision	Recall	F1-Score	ROC-AUC
Regresión Logística	0.6570	0.6061	0.3869	0.4723	0.6883
Árbol de Decisión	0.5695	0.4577	0.4606	0.4592	0.5509
Máquina de Soporte Vectorial (SVM)	0.6448	0.6064	0.2980	0.3997	0.6553


- Diagnóstico:** Los resultados demuestran que evaluar los modelos mediante la exactitud general (Accuracy) genera una falsa sensación de seguridad debido a la asimetría del dataset. Tanto la Regresión Logística como la SVM concentran sus predicciones en la clase mayoritaria, deprimiendo severamente la sensibilidad (Recall). Dejar escapar el 61.31% de las fugas reales en la Regresión Logística invalida la aplicación práctica de este umbral estándar en un entorno corporativo real.

4. Evaluación Avanzada y Calibración de Umbrales Operativos

4.1. Análisis del Compromiso de Métricas (Trade-off)

Para mitigar la debilidad de la línea base, se extrajo el vector continuo de probabilidades de la Regresión Logística por presentar la mayor capacidad discriminante global (ROC-AUC de 0.6883). Se sometió al clasificador a un barrido paramétrico generando la matriz de control `df_umbrales`. El análisis demostró que la métrica de balance armónico (F1-Score) alcanza su máximo global de ~ 0.60 cuando la barrera de riesgo se reduce al rango de 0.25 a 0.35.

Fijando el umbral de decisión en 0.30, el sistema logra un compromiso óptimo: la sensibilidad (Recall) escala de forma exponencial hasta un 80% (detectando a 80 de cada 100 desertores reales), mientras la precisión se ajusta de forma controlada a un ~ 0.48 .



4.2. Justificación Financiera para la Toma de Decisiones

La adopción del umbral optimizado de 0.30 se fundamenta en la asimetría económica de los errores en el negocio bancario:

- Costo de un Falso Positivo (Baja Precisión): Clasificar por error a un cliente estable como propenso a la fuga activa alerta preventivas automatizadas de muy bajo costo operativo (correos institucionales, ofertas de tasas preferenciales o beneficios de fidelización). No genera pérdidas patrimoniales y robustece la presencia de marca.

- Costo de un Falso Negativo (Bajo Recall): No identificar a un cliente evasor representa un impacto crítico directo: pérdida de los saldos capturados, cancelación de flujos transaccionales futuros y la necesidad obligatoria de incurrir en los altos costos comerciales de marketing para adquirir una cuenta nueva que reemplace la vacante.

5. Metodología de Optimización de Hiperparámetros

Para superar las limitaciones operativas de las líneas base y corregir de manera definitiva el sesgo de clasificación provocado por el desbalance de la variable objetivo, se implementó una estrategia de optimización sistemática. Utilizando el módulo GridSearchCV de Scikit-Learn acoplado a una estrategia de validación cruzada estructurada de 5 pliegues (5-Fold Cross-Validation), se evaluaron múltiples combinaciones de hiperparámetros sobre una muestra de entrenamiento homogénea de 16.000 registros explicativos.

5.1. Espacio de Búsqueda y Configuraciones Óptimas Encontradas

El proceso de optimización exploró diferentes configuraciones de regularización, control de sobreajuste y compensación de pesos para cada algoritmo clasificador. La matriz de búsqueda y los resultados óptimos obtenidos tras la convergencia de los optimizadores se detallan a continuación:

5.2. Justificación Técnica de los Resultados de la Optimización

Los parámetros seleccionados automáticamente por el optimizador responden a una sólida lógica de mitigación de errores del modelo y resguardo de la generalización:

1. Activación de Penalización por Desbalanceo (`class_weight='balanced'`): Tanto en la Regresión Logística como en la SVM, el algoritmo seleccionó la opción balanceada. Esto modifica internamente la función de costo del clasificador, penalizando con mayor severidad los errores cometidos sobre la clase minoritaria (los clientes que se fugan). Esta configuración resuelve directamente el problema de los Falsos Negativos masivos identificado en la línea base de la Entrega 2.
2. Control de Varianza en el Árbol de Decisión: La selección de una profundidad máxima limitada (`max_depth=10`) combinada con una exigencia alta de registros por nodo terminal (`min_samples_leaf=20`) actúa como un podado (pruning) matemático preventivo. Esto evita que el árbol memorice el ruido del dataset de entrenamiento, garantizando que el modelo sea capaz de aplicar reglas comerciales estables sobre datos de testeo completamente nuevos.
3. Suavizado de Márgenes Lineales (`C=0.1`): Un valor bajo en el parámetro de regularización para los modelos lineal y SVM incrementa la tolerancia del optimizador ante registros que cruzan la frontera de decisión en la fase de entrenamiento. Esto genera un modelo más

robusto, menos propenso al sobreajuste y con una transición de probabilidades mucho más suave para la posterior calibración operativa del negocio.

6. Conclusiones

6.1. Impacto de la Estrategia de Manipulación de Datos

El desarrollo de esta etapa del sistema predictivo ratifica que el éxito de un modelo de Machine Learning aplicado al sector financiero no depende únicamente de la complejidad del algoritmo, sino de la rigurosidad en el saneamiento de los datos crudos y la estructuración de sus variables. La implementación de un flujo defensivo modular centralizado en `src/data_preprocessing.py` permitió corregir de manera sistemática anomalías críticas como registros duplicados, valores nulos y montos negativos aberrantes mediante su transformación a valor absoluto. Este proceso garantizó un ecosistema de datos limpio, escalable y reproducible de 16.000 registros para el entrenamiento.

6.2. Viabilidad del Negocio mediante Optimización Analítica

La auditoría realizada sobre las líneas base demostró el peligro de evaluar modelos en entornos con desbalance de clases utilizando exclusivamente métricas globales como el Accuracy. El paso fundamental dado por el equipo al aplicar técnicas de Threshold Shifting (calibrando el umbral operativo en 0.30) e integrar búsquedas exhaustivas (GridSearchCV) con penalización de pesos (`class_weight='balanced'`) resolvió la debilidad estructural del sistema. Al elevar la tasa de captura de fuga (Recall) hasta un 80%, la solución analítica transiciona de ser un ejercicio estadístico a convertirse en una herramienta comercialmente viable, capaz de mitigar pérdidas patrimoniales críticas para la institución financiera.